ETL Workshop 2

Airflow – Spotify Analysis


2221222

Joan Mateo Bermudez Collazos

2024

Universidad Autónoma de Occidente Descripcion del reto

El segundo reto se trataba de generar un pipeline de datos que vienen de dos diferentes fuentes de datos (csv, sql) con datos sobre música un dataset sobre los Grammys nominados y el segundo sobre información de canciones sacado del api de Spotify, el objetivo es identificar y estudiar los datos que nos entregan para poder unir los datos de diferentes fuentes para generar así un análisis un poco mas valioso al poder complementar los datos, el reto de esto también es después de identificar y analizar como hacer el merge de los datos poder generar un proceso de etl con airflow donde podremos orquestar un proceso de etl donde al final después de tener los datos limpios y unidos los guardaremos tanto en una base de datos como en Google Drive mediante su API como un archivo csv



La idea es generar un flujo similar al anterior.

Desarrollo del reto

Planeación

Para el reto las tecnologías obligatorias son Python, Airflow, Drive-api, para poder cumplir con lo requerido decidí utilizar docker para la base de datos y wsl (Windows subsistem for linux) para correr el proyecto en general ya que Airflow corre nativamente en sistemas unix, utilizare power bi para la presentación del dashboard y analítica además de los notebooks de python la base de datos se conectara con los notebooks y el orquestador Airflow utilizando la red local de la maquina Ubuntu(wsl) pero cuando se necesite acceder a ella mediante la aplicación de visualización se hará atreves de la red creada por wsl para acceder desde mi maquina local hacia la base de datos que corre en docker dentro de la maquina Linux, la red que se le asigno a tu maquina wsl se pude ver con el siguiente comando ip route show | grep -i default | awk '{ print \$3}'.

instalar lo necesario


- Instala y verifica el funcionamiento de wsl
 Link Documentación: <u>Instalación de WSL | Microsoft Learn</u>
- 2) instalación de los programas para el funcionamiento
 - a. instalar python3 una versión soportada por Airflow recomiendo min 3.9
 - b. instalar docker Link Documentación: <u>Install Docker Engine on Ubuntu | Docker Docs</u>
 - c. recomendable setear la variable de sistema para la ruta de funcionamiento de Airflow dentro del directorio del proyecto echo export

 AIRFLOW_HOME=\$(pwd) >> ~/.bashrc
 - d. instalar Airflow con pip
 Link Documentación : <u>Installation of Airflow™ Airflow Documentation</u>
 (apache.org)
 - e. descargar la imagen de docker para la base de datos postgres16.2-alpine3.19 con el comando docker pull postgres16.2alpine3.19

Creación de archivos de contraseñas y el entorno virtual

- crear los archivos de contraseñas necesarios
 - a. .env
 - b. docker secrets
- creación del entorno virtual python3 -m veny veny
- creación del archivo .gitignore para evitar subir al repositorio los archivos de contraseñas y bases de datos

Generar la estructura de carpetas para el proyecto



Dags

- Carpeta la cual se define como casa de airflow

Data

- Capeta donde leeremos y guardaremos los csvs

DB_Connection

- Carpeta donde creamos las funcionalidades para el manejo de la base de datos Drive
- Carpeta donde crearemos las funcionalidades para el manejo de la api de Google drive

Notebooks

 Carpeta donde revisaremos los datos y apartir de ese analisi definiremos las necesidades del dag

postgres-db-volume

- Carpeta que será utilizada como volumen por docker

Configuración de archivo docker compose

Definimos un servicio llamado postgresdb donde utilizamos la imagen ya antes descargada definimos puertos y volúmenes además de utilizar un archivo de variables de entorno llamado docker-secrets donde pasamos la variable de entorno obligatoria para correr el contenedor docker - Secrets

corremos el contenedor con el comando sudo docker compose up

ingresamos al contenedor y creamos la base de datos en este caso workshop_2

sudo docker exec -it etl workshop 2-postgresdb-1 /bin/bash psql -U postgres


Vemos las tablas y eliminamos las que ya se habían trabajado

```
Schema |
              Name
                          Type
                                    Owner |
 public |
          grammys
                          table
                                  postgres
 public |
          grammys_clean
                          table
                                  postgres
 public | merge
                          table |
                                  postgres
(3 rows)
workshop 2-#;
ERROR: syntax error at or near "drop"
LINE 2: drop table grammys_clean
workshop 2=# drop table merge;
DROP TABLE
workshop 2=# drop table grammys clean;
DROP TABLE
workshop_2=#
```

Ahora que ya tenemos los datos listos para leer podemos empezar el análisis exploratorio

Importamos las librerías necesarias y ya podemos ver algunas de las funciones que estábamos probando

Esta primera función fue diseñada para poder separar los nombres de los que trabajaron con los artistas ya que venían en texto separados por comas y puntos y comas pero al hacerlo me di cuenta que no seguían una misma estructura y muchos no tenían que hicieron en el proyecto aveces aparcia varias veces el nombre o aparecía el parentesco con el artista por lo que decidí que esta columna no iba a dar un análisis consistente.






Esta segunda función permitió separar la fecha de la columna published_at que venia en un formato mas extenso y en string a un formato tipo Date para sql y un análisis mas fácil



Identificamos valores faltantes y duplicados y los trate para mantener la consistencia en el análisis



Vemos que hay muy pocas fechas donde se hicieron los Grammys en nuestro dataset

```
# slock for the sings in this date 2017-11-20
# digrammy|df_grammys.published_date == "2017-11-20"|["wineer"].value_counts()
# syntom

True 4265
Name: count, dtype: int64
```

Vemos que la mayoría están en esta fecha "2017-11-28"



Por ultimo elimine las columnas que no se me hacían interesantes para el análisis en conjunto con el otro dataset como ganador que todo estaba en True fecha de actualización fecha de publicación que ya habíamos transformado en otra columna

Img que era un link a la imagen de la canción y workers que ya vimos que no era muy consistente

Por utlimo volvemos a guardar en la base de datos

```
df_grammys.to_sql("grammys_clean", Pysqlconnect.connection(), if_exists="replace", index_label="id")

228]
... 970
```

Aquí ya hemos identificado las tareas que asignaremos en el workflow para el tratamiento del dataset de Grammys

Spotify EDA

```
#preproces stage import libraries
import pandas as pd
import numby as pt
import numby as pt
import numby as np
from datetime import datetime

Python
```

Empezamos igual importando los módulos necesarios para el trabajo

```
D 

df_spotify["Unnamed: 0"].nunique()

five dont have duplicates but i will delete this column

Python

114000

df_spotify.index

RangeIndex(start=0, stop-114000, step=1)

D 

df_spotify.drop(columns=("Unnamed: 0"), inplace=True)

df_spotify.drop(columns=("Unnamed: 0"), inplace=True)

Python
```

Vemos una columna extraña y identificamos que se trata de una columna tipo index la eliminamos ya que tenemos la columna propia de pandas que también tiene un nombre mas descriptivo de lo que es.

Buscamos valores nulos pero encontramos que solo hay una fila con nulos en todo el dataset

```
df spotify.info()
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 114000 entries, 0 to 113999
Data columns (total 20 columns):
    Column
                    Non-Null Count
                                    Dtype
 0
    track id
                    114000 non-null object
    artists
 1
                   113999 non-null object
 2
    album name
                    113999 non-null object
 3
    track name
                    113999 non-null object
 4 popularity
                    114000 non-null int64
                    114000 non-null int64
    duration ms
    explicit
                    114000 non-null bool
 6
    danceability
                    114000 non-null float64
                    114000 non-null float64
 8
    energy
                    114000 non-null int64
 9
    key
                  114000 non-null float64
 10 loudness
                    114000 non-null int64
 11 mode
 12 speechiness
                   114000 non-null float64
                  114000 non-null float64
 13 acousticness
 14 instrumentalness 114000 non-null float64
              114000 non-null float64
 15 liveness
                   114000 non-null float64
 16 valence
 17 tempo
                   114000 non-null float64
 18 time_signature
                    114000 non-null int64
 19 track genre
                    114000 non-null object
dtypes: bool(1), float64(9), int64(5), object(5)
memory usage: 16.6+ MB
```



ELIMINAMOS y eliminamos duplicados




Después de eliminar duplicados seguimos viendo a mas profundidad y vemos que cuando filtramos por algunas columna con información sobre la canción que si es la misma muy probablemente sea la misma canción y nos encontramos con una falla en la consistencia de los datos y es que hay canciones duplicadas donde su única diferencia es su clasificación de genero esto probablemente por la forma en que se obtuvieron los datos originalmente que pude leer en kaggle fue por medio de una api utilizando descargas por genero





Creamos un dataframe excluyendo los duplicados esta vez por id de canción únicamente y ya nos quedamos sin canciones duplicadas

Luego de haber identificado la limpieza necesaria para cada dataset crudo empezamos a definir las funciones que serán utilizadas por Airflow entonces empezamos a escribirlas para que puedan ser utilizadas dentro de Airflow y las escribiremos dentro de la carpeta dags esto no es necesario



```
import sys
sys.path.append("/home/joan/Desktop/etl_workshop_2/DB_Connection")
import Pysqlconnect
import pandas as pd
from datetime import datetime
import logging
import json
logging.basicConfig(level=logging.INFO)
logger = logging.getLogger("[Grammys:logs]")
def Extract()->json:
    """This function load the data from postgres db to dataframe pandas"""
    try:
        df_grammys = pd.read_sql(sql="SELECT * FROM grammys;",
                             con=Pysqlconnect.connection()) #load the data using own module
        logger.log(level=20, msg=f"[{datetime.now()}] - Postgres Connected --- data-loaded -
        return df_grammys.to_json(orient="records")
    except Exception as err:
        logger.error(f"[{datetime.now()}]: {err}")
        return None
def datetime_transform(stdate:str)->datetime:
    """This function is used for transform one string to datetime format sql"""
        date = datetime.strptime(stdate, '%Y-%m-%dT%H:%M:%S%z')
        formatdate = date.strftime('%Y-%m-%d') #this is the format to date to sql
        return formatdate
    except Exception as err:
        logger.error(f"[{datetime.now()}] - {err}")
def add column published date(**kwargs:json)->json:
    try:
        logger.log(level=20, msg=f"[{datetime.now()}] - start 'add_column_published_date'")
        ti = kwargs["ti"]
        json_df = json.loads(ti.xcom_pull(task_ids="extract_grammys_task"))
        df = pd.json_normalize(data=json_df)
        df["published_date"] = df["published_at"].apply(datetime_transform)
        logger.log(level=20, msg=f"[{datetime.now()}] - finish task")
        return df.to_json(orient="records")
    except Exception as err:
        logger.error(msg=f"[{datetime.now()}] - {err}")
```

```
from datetime import datetime
import logging
logging.basicConfig(level=logging.INFO)
logger = logging.getLogger("[Spotify:logs]")
def Extract()->json:
    try:
    logger.log(level=20, msg=f"[{datetime.now()}] - start Extract")
    df = pd.read_csv("/home/joan/Desktop/etl_workshop_2/Data/spotify_dataset.csv")
    logger.log(level=20, msg=f"[{datetime.now()}] - data extracted")
          return df.to_json(orient="records")
          logger.error(msg=f"[{datetime.now()}] - {err}")
def drop_fake_index_col(**kwargs)->json:
          logger.log(level=20, msg=f"[{datetime.now()}] - start drop_fake_index")
          ti = kwargs["ti"]
          json_dis = json.loads(ti.xcom_pull(task_ids="extract_spotify_task"))
df = pd.json_normalize(data=json_df)
          try:
    df.drop(columns=('Unnamed: 0'), inplace=True)
               logger.log(level=20, msg=f"[{datetime.now()}] - finish drop_fake_index")
               return df.to_json(orient="records")
         logger.log(level-20, msg=f"[{datetime.now()}] - finish drop_fake_index")
return df.to_json(orient="records")
      logger.error(f"[{datetime.now()}] - {err}")
def drop_duplicates(**kwargs)->json:
          logger.log(level=20, msg=f"[{datetime.now()}] - start drop duplicates")
          ti = kwargs["ti"]
          json_df = json.loads(ti.xcom_pull(task_ids="drop_fake_index_col_task"))
df = pd.json_normalize(data=json_df)
          df.drop_duplicates(inplace=True)
          df = df[df["track_id"].duplicated() == False]
logger.log(level=20, msg=f"[{datetime.now()}] - finish drop duplicates")
return df.to_json(orient="records")
           logger.error(msg=f"[{datetime.now()}] - {err}")
```

Luego el archivo del dag donde se organizara todo el flujo


```
🕏 spotify.py Dags/dags/Spotify_dag/spotify.py/...
     IT OIL STOLE TIMPOLE STOLE MATE
13
     default args = {
          'owner': 'airflow',
          'depends on past': False,
          'start date': datetime(2024, 4, 1),
          'email on failure': False,
          'email on retry': False,
          'retries': 3,
          'retry_delay': timedelta(minutes=5),
     dag = DAG(
          'Spotify',
         default args=default args,
         description='Etl process to grammys analysis',
         schedule interval=timedelta(days=1),
     def log task execution(task name, **kwargs):
         print(f"Executing task: {task_name}")
     with dag:
         extract spotify task = PythonOperator(
             task_id='extract_spotify_task',
             python_callable=ExtractSpotify,
         drop_fake_index_col_task = PythonOperator(
             task id='drop fake index col task',
             python callable=drop fake index col,
         drop_duplicates_task = PythonOperator(
             task_id='drop_duplicates_task',
             python callable=drop duplicates,
         extract_grammys_task = PythonOperator(
             task_id='extract_grammys_task',
             python callable=ExtractGrammys,
         add column published date task = PythonOperator(
              task id='add column published date task',
             python_callable=add_column_published_date,
         drop_columns_task = PythonOperator(
```

```
extract_spotify_task >> drop_fake_index_col_task >> drop_duplicates_task >> merge_dataset
extract_grammys_task >> add_column_published_date_task >> drop_columns_task >> drop_nulls_task >> merge_dataset
merge_dataset >> load_data >> Drive_upload
```

Luego podemos correr el Airflow


```
| Company | Comp
```

Con Airflow standalone




Verificamos en la web que este el dag que creamos en este caso se llama Spotify

Luego para verificar que funcióna corremos y vemos la base de datos y el Drive




Vemos el drive vacio

Y postgres sin las tablas




Después de correr



```
Name
                  lype
 public | grammys | table | postgres
(1 row)
workshop_2=# \d
          List of relations
 Schema
                    Type
                             Owner
 public
          grammys
                    table
                            postgres
 public | merge
                  | table |
                            postgres
(2 rows)
workshop 2=#
```

Los datos han sido cargados por lo que podemos decir que el pipeline tuvo éxito

Por ultimo podemos ver el tablero en power bi



Al final mi flujo termino siendo algo así

